

# Lista 02

MEC 2403 - Otimização e Algoritmos para Engenharia Mecânica

**Pedro Henrique Cardoso Paulo**

pedrorjpaulo.phcp@gmail.com

Professor: Ivan Menezes



Departamento de Engenharia Mecânica  
PUC-RJ Pontifícia Universidade Católica do Rio de Janeiro  
abril de 2023

# Lista 02

## MEC 2403 - Otimização e Algoritmos para Engenharia Mecânica

Pedro Henrique Cardoso Paulo

abril de 2023

### 1 Introdução

#### 1.1 Objetivos

Esse é o entregável da Lista 02 da disciplina MEC 2403 - Otimização e Algoritmos para Engenharia Mecânica. Esse trabalho tem como objetivos:

1. Implementar os principais métodos determinação de direções para otimização em múltiplas variáveis
2. Aplicar esses métodos em funções 2D com o uso de passos analíticos
3. Exercitar a linguagem de programação e as ferramentas de visualização gráfica

#### 1.2 Links úteis

Nesta seção são listados alguns links e referências úteis para se entender o trabalho desempenhado.

1. [Apostila de programação matemática da disciplina](#)
2. [GitHub usado para essa disciplina](#)
3. [Notebook com o código para as figuras desse relatório](#)
4. [Pasta com os códigos a serem aproveitados em todas as listas](#)

### 2 Questão 01

#### 2.1 Enunciado

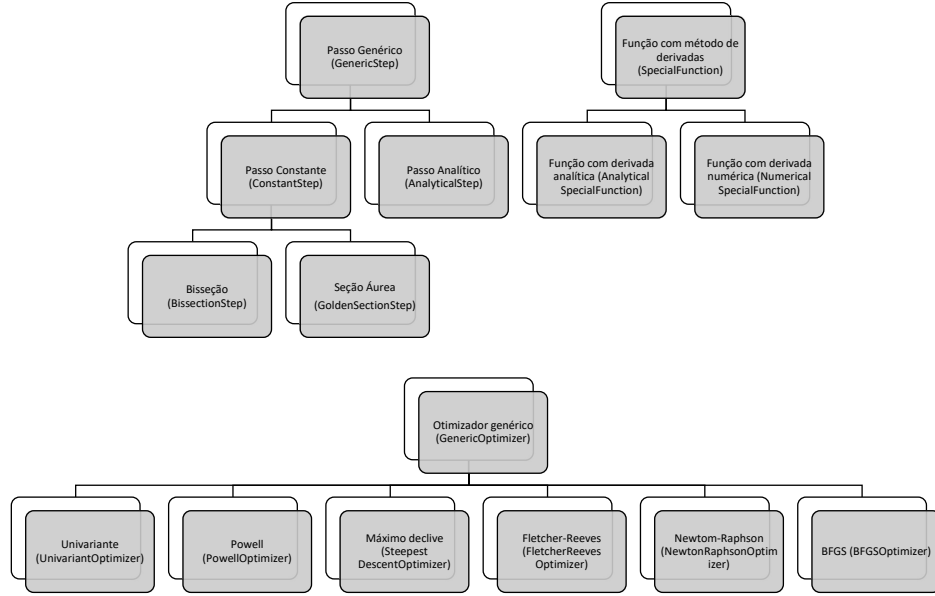
Dada a função  $f(x_1, x_2) = x_1^2 - 3x_1x_2 + 4x_2^2 + x_1 - x_2$ , minimizá-la partindo do ponto  $\mathbf{x}^0 = [2, 2]^T$  utilizando os métodos de otimização: (a) *Univariate*; (b) *Powell*; (c) *Steepest Descent*; (d) *Fletcher-Reeves*; (e) *BFGS*; e (f) *Newton-Raphson*.

Preencher uma tabela com os resultados obtidos adotando uma tolerância de  $10^{-5}$  e um número máximo de 3 passos para cada método. Para cada passo (iteração) de cada método indicar o valor de  $\alpha$  obtido na busca linear.

#### 2.2 Solução

A execução deste exercício demandou uma pequena refatoração do código do pacote `steps.py`, desenvolvido para a solução da [Lista 01](#). Essa refatoração implicou na criação de uma classe de passo genérico (`GenericStep`) da qual passos dissociados do passo constante pudessem herdar. Além disso, mais dois arquivos foram criados: `functions.py`, onde foi definido um objeto capaz de armazenar as informações de uma função, seu gradiente e sua Hessiana para casos analíticos e numéricos e `optimizers.py`, onde foram definidos objetos responsáveis pela execução dos métodos de otimização (sua definição de direção de busca e iteração até a convergência). A Figura 1 exemplifica o resultado final das classes implementadas. Mais detalhes da implementação dos otimizadores será apresentado no Trabalho 01, em elaboração.

Como o principal objetivo do presente exercício é validar a implementação dos métodos de otimização e a função a ser estudada é sabidamente quadrática, dada uma direção de busca  $\mathbf{d}_i$ , o valor do passo linear ideal  $\alpha_i$  pode ser calculado com base no gradiente da função  $\nabla f$  e em sua Hessiana  $\mathbf{H}(f)$  por meio da equação 1.



**Figura 1:** Estrutura de classes implementada e heranças

$$\alpha_i = \frac{\nabla f^T \mathbf{d}_i}{\mathbf{d}_i^T \mathbf{H}(f) \mathbf{d}_i} \quad (1)$$

Para a função  $f(x_1, x_2)$  descrita no enunciado, o gradiente e sua Hessiana são descritos nas equações 2 e 3.

$$\nabla f = \begin{bmatrix} 2x_1 - 3x_2 + 1 \\ -3x_1 + 8x_2 - 1 \end{bmatrix} \quad (2)$$

$$\mathbf{H}(f) = \begin{bmatrix} 2 & -3 \\ -3 & 8 \end{bmatrix} \quad (3)$$

Essa equação foi implementada como um objeto chamado `AnalyticalStep` para ser passada aos métodos de otimização. O código desse objeto é mostrado abaixo:

```

class AnalyticalStep(GenericStep):

    def __init__(self):
        super().__init__()

    def __call__(self, p_initial, direction, function):

        grad = function.grad(*p_initial).reshape(-1,1)
        direction = direction.reshape(-1,1)
        Q = function.Hessian(*p_initial)

        ak = - np.dot(grad.T, direction) / (direction.T @ Q @ direction)
        ak = ak.reshape(-1)[0]

        pend = pend = p_initial + ak*direction.reshape(-1)

        return ak, pend

```

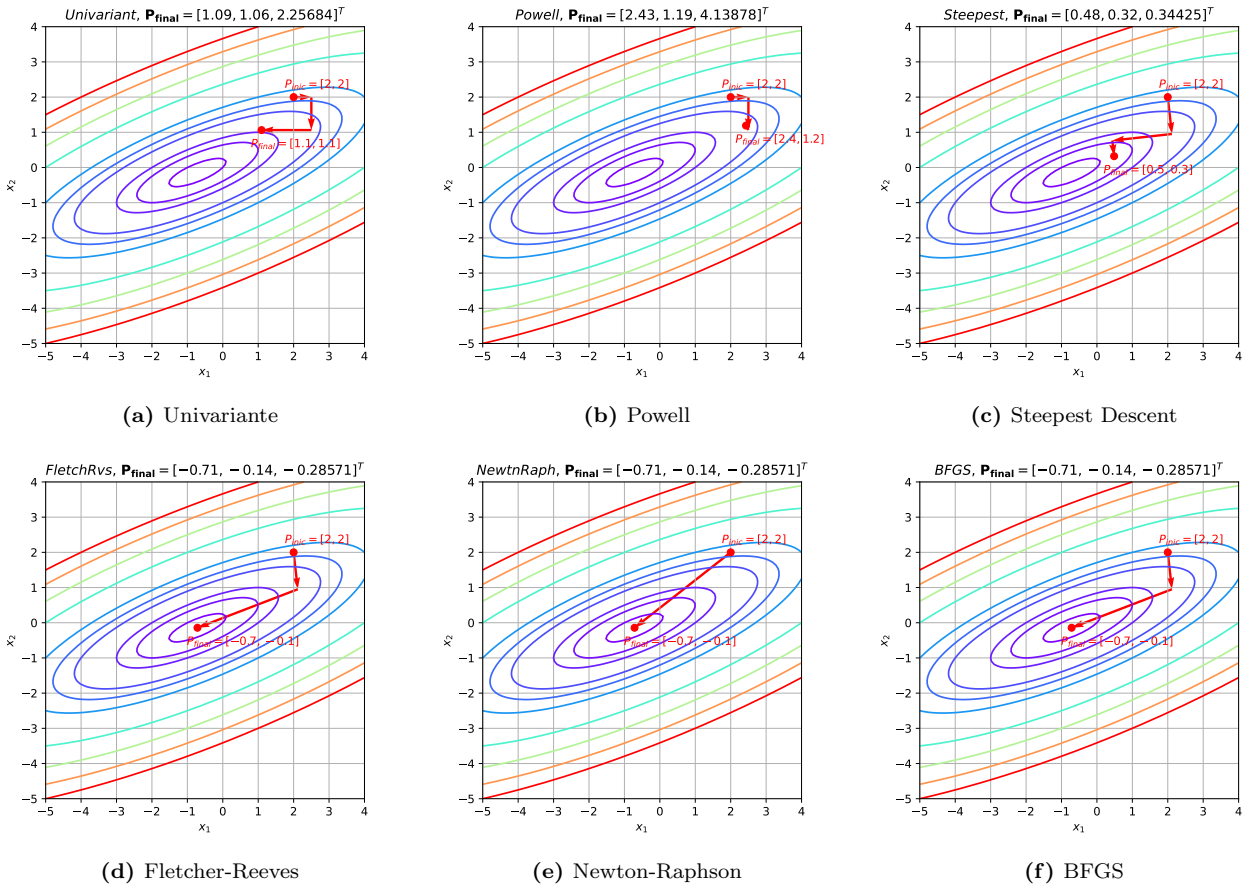
Ressalta-se que o critério de parada usado para os otimizadores foi o critério de parada aplicado para a otimização foi, no presente estudo, um limite de 3 iterações e uma condição de chegada ao ponto crítico definida pela equação 4, com a tolerância  $tol$  sendo igual a  $10^{-5}$ .

$$|\nabla f| \leq tol \quad (4)$$

Os resultados finais das 3 iterações executadas são resumidos na Tabela 1, com os resultados por passo em forma gráfica sendo mostrados na Figura 2. Nota-se a partir dos resultados que os valores finais obtidos foram coerentes com o previsto pela teoria, com os métodos Fletcher-Reeves, Newton-Raphson e BFGS sendo os únicos a terem convergido no total de 3 passos ou menos, conforme esperado. Além disso, nota-se que o passo analítico para o método de Newton-Raphson retornou também um valor de 1 na única iteração que este precisou, o que novamente está de acordo com o esperado pelo desenvolvimento teórico do método. Também é interessante notar que os métodos de Powell e Univariate apresentaram passos iguais nas duas primeiras iterações, algo que novamente corrobora com a boa implementação dos métodos dado que eles são idênticos nessas duas iterações.

Método	Ponto de mínimo	Passos	$\alpha_1$	$\alpha_2$	$\alpha_3$
Univariate	$[1.093750, 1.062500, 2.256836]^T$	3	0.50000	-0.93750	-1.40625
Powell	$[2.432024, 1.189955, 4.138784]^T$	3	0.50000	-0.93750	-0.13596
Steepest Descent	$[0.484934, 0.320841, 0.344249]^T$	3	0.11647	0.70690	0.11648
Fletcher-Reeves	$[-0.714286, -0.142857, -0.285714]^T$	2	0.11647	1.22648	—
Newton-Raphson	$[-0.714286, -0.142857, -0.285714]^T$	1	1.00000	—	—
BFGS	$[-0.714286, -0.142857, -0.285714]^T$	2	0.11647	1.22648	—

**Tabela 1:** Resumo dos resultados obtidos



**Figura 2:** Resumo gráfico dos passos dados em cada método